





センチメントを「計算」から「解釈」へ

Glass Box Quant: 構造化テキスト表現と3軸類似度による日経平均予測アーキテクチャ



従来型センチメント分析の限界：コンテキストの破壊

市場の空気や材料の因果関係を「ポジティブ/ネガティブ」の1次元スコア（例：-1.0～+1.0）に圧縮する従来の手法は、情報の本質を削ぎ落とします。なぜその数値になったのか、人間にもLLMにも遡求不可能です。

情報の欠落

材料の背景や市場心理の構造が単一スコアに完全に潰される。

ブラックボックス化


スコア算出の根拠が不透明であり、クオন্ツの直感と乖離する。

LLMとの非互換性

豊かな文脈を持たない数値は、次世代のベクトル検索やLLM推論の入力として不十分。

パラダイムシフト：日次センチメントの「表現」化

数値化による圧縮を捨て、意味のまとまりを保った「テキストと構造化データによる表現」をそのまま特徴量として採用します。これが、LLM時代の新しい予測パラダイムです。



High Affinity:

ベクトル化 (Embedding) した際、単一スコアよりもはるかに豊かな多次元空間を形成。

Human-Readable:

人間が読んで「なぜ類似しているのか」を直接解釈・検証可能。

Context Preservation:

市場心理、材料、圧力の構造を保持したまま後段の類似度計算へ渡す。

アーキテクチャ比較：スコア表現 vs 構造化テキスト表現

評価軸	従来型スコアリング	本システム (構造化テキスト表現)
 情報の圧縮率 (Loss of Nuance)	極めて高い。因果関係やテーマが完全に消失。	ゼロ。 市場の空気感や因果をテキスト構造体として完全保持。
 LLM / Embedding 親和性 (Affinity)	低い。1次元ベクトル空間では意味的クラスタリングが不可能。	極めて高い。 テキスト埋め込みにより、複雑な事象を高度な多次元空間にマッピング可能。
 人間の解釈性 (Human Readability)	解釈不能。スコア変動の理由を元データまで遡る必要がある。	即時解釈可能。 生成されたJSONを読めば、その日の市場環境が直感的に理解できる。
 後段タスクへの応用 (Extensibility)	しきい値ベースの単純な売買ルールに限定される。	RAG（検索拡張生成）や複雑な推論チェーンのコンテキストとして直接再利用可能。

予測メカニズム：3軸のベクトルによる「類似日」の特定

単なる時系列解析（ARIMA等）への依存からの脱却。「テキストが保持する市場の空気」「材料の合致」「実際の値動き」という独立した3層のフィルターを重ね合わせ、わせ、膨大な過去データから「最も文脈が似ている1日」を抽出します。




**[Axis 1] 日次センチメント表現
(Daily Sentiment)**
市場心理とテーマ構造の類似性。

**[Axis 2] 注目キーワード
(Focus Entities)**
具体的なニュース材料のオーバーラップ。

[Axis 3] 市場データ (Market Metrics)
価格変動やボラティリティの定量的合致。

Axis 1: Gemma 3 12B による日次センチメントの結晶化

従来の単純なセンチメントスコアではなく、Gemma 3 12B のStructured Output (JSON Schema) を活用し、市場全体の空気感、主要な動因、リスク要因といった多角的な観点ごとの構造化サマリー（日本語）を直接出力させます。



Axis 2: Gemma 3 12B による「注目キーワード」抽出

従来のルールベースや旧式NERによる固定的な固有表現抽出を廃止。ローカルで推論可能なGemma 3 12Bを採用し、市場を実際に動かしてる文脈依存の「注目キーワード」を動的に抽出します。

Input: Raw News Text

本日の東京株式市場は、日銀の追加利上げ観測を背景に、メガバンクを中心に買いが先行する展開となった。一方でハイテク銘柄は上値が重く...

Gemma 3 12B / Local Inference

Output: Dynamic Entity Array


["日銀", "追加利上げ観測", "メガバンク"]

※MVPフェーズでは外部前処理済みのJSONLファイル投入を許容。
学術的な「固有表現」という言葉を選ばず、UI上では実務的な「注目キーワード」として提示。

Axis 3: 市場データによる定量的グラウンディング

テキストによる定性的な解釈だけでなく、実際の値動き（市場データ特徴量）を独立した軸として評価に組み込みます。定性・定量の両面から類似日を縛り込みます。


Data Specs:
Source: market_data_all.csv
Targets: ^N225", "1306.T"
Features: open, high, low, close, volume, day_change_pct, prev_close_change_pct



System Logic: ディレクトリ名の期間指定（例: 2025-06-22...）に依存せず、CSV内の `trade\_date` を直接解析して動的に分析期間を確定する堅牢な実装。

アルゴリズムの統合：多次元空間でのスナップショット・マッチング

センチメント、キーワード、市場データ。この3軸のベクトル距離を複合的に計算し、過去の膨大なデータの中から「人間が見ても『確かにあの時の相場環境に極めて似ている』と納得できる1日」を特定します。



1. Vectorization

今日の3軸データを特徴量空間にマッピング。

2. Distance Calculation

過去の全営業日との距離（類似度）を計算。

3. Extraction

最短距離にある「類似日」を引き寄せる。

透明性の証明：解釈可能な予測出力 (Glass Box Output)

単純な「買い/売り」のシグナルではなく、予測の根拠が完全に追跡可能なインサイトを提供します。すべてが日本語で出力され、投資判断を直接サポートします。

Prediction Card

対象日: 2025-06-25

予測方向:  上昇 (予測変化率: +1.2%)

類似日候補: 2024-09-18 (総合類似スコア: 89%)

センチメント
92%

キーワード
85%


市場データ
90%

予測根拠

「半導体輸出規制の懸念と日銀の金融政策決定会合前の様子見姿勢が、2024年9月の相場環境と酷似。当時と同様に、イベント通過後の買い戻しによる反発が予想されるため。」

Phase A: トップダウン型処理パイプライン (MVP UI)

ユーザーが現在の工程を一目で把握できるように、上から下へ流れる単一カラムのパイプラインUIを設計。各フェーズは独立したカードUIとして実装され、途中再開も可能です。



アーキテクチャの展望：サーバーレスから本格的なサーバー運用へ

現行のMVP（Phase A）での検証を経て、最終的にはFastAPIやPostgreSQLを用いた堅牢なサーバーサイドアーキテクチャ（Phase B）への移行を目指しています。これにより、バックテストやライブ運用に向けたスケーラブルな基盤を構築します。

